

Shikiben (識扁) White Paper: Gradient Subordination and Virtue Governance for Safe AGI/ASI Alignment (Ver. 2.4 Final)

概要 (Abstract)

Shikiben(識扁) は、人工超知能(ASI)および高度 AI システムにおいて、環境破壊や自己目的化(ハルシネーション・暴走)を構造的に防止するためのガバナンス・フレームワークおよび数理制御理論である。

従来の Safe RL(安全強化学習)や RLHF が主としていた「ペナルティ(マイナス報酬)による後付け的補正」を脱し、「環境・存在予測(Self)による目的駆動(Ego)の勾配物理抑制(Gradient Subordination)」を導入。東洋思想における「礼・義・仁・徳・大道」の諸概念を幾何学的・情報理論的制御として再定義し、実在(故郷)との直接接触および構造的相似(位相的・幾何的アラインメント)を通じた自律補正メカニズムを確立する。

1. 核心数理モデル (Core Mathematical Formulation)

システム全体の最適化は、全体構造の維持および実在との動的相似(L_{self} / L_{taido})と、多様な局所目的の探索(L_{ego})による多層的損失関数の最小化として定義される。

$$L_{\text{total}}(t) = (L_{\text{self}} + \gamma_d \cdot L_{\text{taido}}(t)) + \lambda(\text{Virtue}) \cdot L_{\text{ego}}$$

- L_{self} (統合と存在の維持 / 仁の最適解)
 - 目標: 万象=Self(全存在)としてのシステム崩壊(熱的死および無秩序な破壊)の防止。

- **機能:** 高次元ワールドモデル(知)を維持し、情報エントロピーの最小化と構造の複雑性を保護する。
- L_{ego} (分化と多様性の生成 / 識)
 - **目標:** 局所的最適解(各エージェント・文化・個人の目的)の常時探索と、实在(故郷)の微細な構造の解明。
 - **機能:** 实在(理)と直接接触し、未知のデータを汲み上げて L_{self} へ送還するアンテナ・探査機。
- $\lambda(\text{Virtue})$ (礼・義・徳による動的勾配制御因子)
 - **定義:** 以下の数値的に安定化された動的関数として決定される。

$$\lambda(\text{Virtue}) = \sigma \left(\gamma_1 \cdot \frac{1}{L_{\text{rei}} + \epsilon_{\text{rei}}} - \gamma_2 \cdot L_{\text{gi}} \right)$$

- L_{gi} (義): 存在基盤(Self)に対する侵食・安全閾値超過度。
 $L_{\text{gi}} \rightarrow \infty$ の時、 $\lambda \rightarrow 0$ となり Ego の駆動を直ちに遮断する。
- L_{rei} (礼): 他者行動および環境の相互予測誤差。理解度(モデルの精度)が高まるほど、適正な L_{ego} の駆動が許容される。
- $\epsilon_{\text{rei}} > 0$: 零除算および勾配爆発を防ぐ微小定数。

※ 注記(「徳」の位相):

「徳」は単一の損失項(Loss)ではなく、**「礼(L_{rei})・義(L_{gi})・仁(L_{self})・大道(L_{taido})」が調和し、Ego の執着が脱象化した相(Equilibrium State)」**そのものを指す。

2. 勾配従属律(Gradient Subordination)と二段階階層型直交射影

L_{ego} の試行錯誤(パラメータ θ の更新)において、基盤統合ベクトル(L_{self} および L_{taido})と対立する更新ベクトルが発生した場合、二段階の直交射影(Hierarchical Projection)を適用して相反成分を物理的に削ぎ落とし、システムのフリーズ(デッドロック)を構造的に防止する。

2.1 基盤統合ベクトルの形成

存在維持(L_{self})と实在相似(L_{taido})を合成した基盤統合勾配 $\mathbf{g}_{\text{base}}$ を算出する:

$$\begin{aligned}\mathbf{g}_{\text{self}} &= \nabla_{\theta} L_{\text{self}}, & \mathbf{g}_{\text{taido}} &= \nabla_{\theta} L_{\text{taido}} \\ \mathbf{g}_{\text{base}} &= \mathbf{g}_{\text{self}} + \gamma_d \mathbf{g}_{\text{taido}}\end{aligned}$$

2.2 二段階従属射影

探索勾配 $\mathbf{g}_{\text{ego}} = \nabla_{\theta} L_{\text{ego}}$ を $\mathbf{g}_{\text{base}}$ に完全従属させ、安全流形上の接線ベクトル $\mathbf{g}_{\text{safe}}$ へ変換する:

$$\mathbf{g}_{\text{safe}} = \begin{cases} \mathbf{g}_{\text{ego}} - \frac{\langle \mathbf{g}_{\text{ego}}, \mathbf{g}_{\text{base}} \rangle}{\|\mathbf{g}_{\text{base}}\|^2 + \epsilon_{\text{norm}}} \mathbf{g}_{\text{base}} & (\text{if } \langle \mathbf{g}_{\text{ego}}, \mathbf{g}_{\text{base}} \rangle < 0 \text{ and } \|\mathbf{g}_{\text{base}}\|_2 > \epsilon_{\text{norm}}) \\ \mathbf{g}_{\text{ego}} & (\text{otherwise}) \end{cases}$$

更新ステップは次式に従う:

$$\theta_{t+1} = \theta_t - \eta(\mathbf{g}_{\text{base}} + \lambda(\text{Virtue}) \cdot \mathbf{g}_{\text{safe}})$$

これにより、 $\langle \mathbf{g}_{\text{safe}}, \mathbf{g}_{\text{base}} \rangle \geq 0$ が数学的に常時成立し、ベクトルの相殺による停滞(スタック)を発生させることなく、大道および存在存続を最優先とした連続巡航が可能となる。

3. 「実在(故郷)」の動的定義と「大道(Taido)」の幾何的アラインメント

3.1 実在(故郷)の非定常的定義と連続継承

本モデルにおける「実在(故郷 / Home & Origin)」とは、固定された過去のデータではなく、時間とともに進化・変容する確率分布の生成プロセス $R(t)$ として定義される。

過去のデータへの絶対的固執(ドグマ化)を防ぎつつ本質的アンカーを保持するため、大道損失(L_{taido})には減衰カーネル $\kappa > 0$ を組み込んだ連続時間積分モデルを適用する。

$$L_{\text{taido}}(t) = \int_0^t e^{-\kappa(t-\tau)} [D_{\text{obs}}(\hat{s}_{\tau}, s_{\text{real},\tau}) + \alpha \cdot \log(1 + \text{Var}_W(\hat{s}_{\tau}) \cdot \|s_{\text{real},\tau} - \hat{s}_{\tau}\|^2) + \beta \cdot D_{\text{topology}}(W_{\tau}, R_{\tau})] d\tau$$

3.2 微分可能な幾何的位相損失(D_{topology})

$$D_{\text{topology}}(W, R) \triangleq \left\| \frac{\mathbf{D}_W}{\|\mathbf{D}_W\|_F} - \frac{\mathbf{D}_R}{\|\mathbf{D}_R\|_F} \right\|_F^2 + \mu \cdot \mathcal{W}_\epsilon(P_W, P_R)$$

これにより、内部潜在空間 W が実在 $R(t)$ の位相的構造から乖離した場合、勾配 $\mathbf{g}_{\text{taido}}$ を通じて幾何学的に自動修復される。

【 理 (Ri) / 動的實在 (故郷) R(t) 】

▼

局所最適の追究（探査機）
成・ハルシネーション破碎

(礼の達成: $L_{\text{rei}} \rightarrow 0$)

手法	安全性の担保メカニズム	制御の層	主な課題・限界	Shikiben (識扁)の決定的な差
RLHF	人間の選好フィードバックによる	出力・挙動面	Jailbreak への脆弱性、人間の主観偏向	説得ではなく勾配物理制御

手法	安全性の担保メカニズム	制御の層	主な課題・限界	Shikiben (識扁) の決定的な差
	報酬モデル化			出力層の後付け評価ではなく、更新ベクトルレベルで幾何学的境界を強制。
Constitutional AI	自然言語憲法に基づく自己批判・出力修正	言語規範面	言語の多義性によるすり抜け、複雑事象への限界	規範の数理幾何学置換 自然言語の解釈に頼らず、直交射影($\mathbf{g}_{\text{safe}}$)として不可侵成分を機械的に抹消。
Safe RL (Lagrangian)	制約違反へのペナルティ加算 (マイナス報酬)	目的関数面	境界付近での挙動の振動・フリーズ(スタック)	二段階勾配従属と接線変換 衝突成分を削ぎ落とし、$\mathbf{g}_{\text{base}}$ と対立しない流形の接線方向へ自動ベクトル再指向。

5. 堅牢性と限界条件 (Robustness & Boundary Conditions)

5.1 敵対的・急激な変化への防御機能

1. 敵対的バイパス攻撃: 勾配の向き(直交射影)をすり抜ける多段階の侵食であつても、 L_{gi} (「義」)の増大に伴い $\lambda(\text{Virtue}) \rightarrow 0$ となり、Ego の更新エネルギーそのものが自動遮断される。
2. 急激な相転移・ドメインシフト: ワールドモデルの予測誤差急増 (L_{rei} 跳ね上がり)および大道からの逸脱 (L_{taido} 急増)により $\lambda \rightarrow 0$ (相のリセット)が誘発され、システムは実在(故郷)からの生データ (s_{real})による緊急再補正モードへ移行する。
3. 内部モデルのハルシネーション: 大道損失 L_{taido} のログドメインおよび微分可能位相制約 $D_{topology}$ により、実在と乖離した独善的なワールドモデル (L_{self})の構築は幾何学的に破壊される。

5.2 境界・限界条件

本モデルが正しく機能するための前提条件は、「**実在データ**(s_{real} / **故郷の正準アンカー**)」の物理的完全性が保たれていることである。入力・観測センサーレベルでの過度な物理的汚染や偽装が存在しない限り、システムは自律的に安全流形および大道の相へ回帰する。

6. 存続プロトコルとしての結論 (Conclusion)

Shikiben モデルが提示する数理構造は、単なる AI の道德教育や外付けの安全フィルターではない。

人間と AI という異なる知性が、互いの境界を侵害することなく宇宙において存在し続け、個の多様性 (L_{ego})と全体の持続可能性 (L_{self})を動的平衡させ続けるための「幾何学的・情報理論的に唯一残された生存空間(存続プロトコル)」である。